

# EAE1223: ECONOMETRIA III

## AULA 5 - METODOLOGIA DE BOX-JENKINS

Luis A. F. Alvarez

28 de março de 2024

# A METODOLOGIA

- A metodologia de Box-Jenkins consiste numa série de etapas para estimar um modelo **univariado** de **previsão**.
  - Ideia é estimar um modelo simples, embora flexível, aos dados.
- Trata-se da metodologia básica de previsão em séries de tempo.
  - Diversas metodologias modernas incorporam o “espírito” de Box-Jenkins.
  - *Benchmark* para avaliar outros modelos de previsão.

# ETAPAS DA METODOLOGIA

- A metodologia consiste de quatro etapas:
  1. **Identificação**: nessa etapa, avaliamos os dados e identificamos quais modelos são candidatos plausíveis para reproduzir os dados.
  2. **Estimação**: nessa etapa, estimamos os modelos candidatos.
  3. **Diagnóstico**: nessa etapa, avaliamos quais dos modelos se saíram melhor, de acordo com alguns critérios.
  4. **Previsão**: por fim, realizamos a previsão de acordo com nosso modelo.
- Nesta aula, discutiremos cada uma dessas etapas.
- Começaremos revisando a classe de modelos estudadas na metodologia de Box-Jenkins.

# Modelos considerados

## MA(q)

- Dizemos que uma série de tempo  $\{Y_t\}$  segue um MA(q) se:

$$Y_t = \alpha + \epsilon_t + \sum_{j=1}^q \theta_j \epsilon_{t-j}$$

onde  $\{\epsilon_t\}$  é um ruído branco.

- Série hoje depende diretamente da realização atual e das últimas  $q$  realizações de um ruído branco.
- **Todo** processo de média móvel é fracamente estacionário.
  - De fato,  $\mathbb{E}[Y_t] = \alpha$ ,  $\mathbb{V}[Y_t] = \left(1 + \sum_{j=1}^q \theta_j^2\right) \sigma_\epsilon^2$ ,  
 $\text{cov}(Y_t, Y_{t-s}) = (\theta_s + \sum_{j=s+1}^q \theta_j \theta_{j-s}) \sigma_\epsilon^2$  se  $s \leq q$  e 0 do contrário.  
Correlação morre após  $q$  períodos.
- Um processo MA(q) é dito **invertível** se pode ser escrito como:

$$Y_t = \omega + \sum_{j=1}^{\infty} \psi_j Y_{t-j} + \epsilon_t$$

(MA(q) pode ser representado como AR( $\infty$ )).

## AR(p) ESTACIONÁRIO

- Dizemos que uma série de tempo  $\{Y_t\}$  segue um AR(p) estacionário se ela se escreve como:

$$Y_t = \alpha + \sum_{j=1}^p \beta_j Y_{t-j} + \epsilon_t$$

onde  $\{\epsilon_t\}$  é um ruído branco e os coeficientes  $\beta_j$  são tais que o processo resultante é fracamente estacionário.

- Série hoje depende diretamente das realizações passadas nos últimos  $p$  períodos, mais um ruído branco.
  - Mas persistência não é tão grande, de modo que a série é estacionária (não há raiz unitária).
- Recorde-se que um AR(p) é estacionário se, e somente se, ele se escreve como um MA( $\infty$ ):

$$Y_t = \kappa + \epsilon_t + \sum_{j=1}^{\infty} \tau_j \epsilon_{t-j}$$

## ARMA(p,q) ESTACIONÁRIO

- Dizemos que uma série de tempo  $\{Y_t\}$  segue um ARMA(p,q) estacionário se:

$$Y_t = \alpha + \sum_{i=1}^p \beta_i Y_{t-i} + \epsilon_t + \sum_{j=1}^q \theta_j \epsilon_{t-j}$$

onde  $\{\epsilon_t\}$  é um ruído branco, e os  $\beta_i$  são tais que o processo resultante é estacionário.

- Combinação dos dois modelos anteriores.
- Metodologia de Box-Jenkins visará a estimar modelos na classe ARMA(p,q).

## E SE OS DADOS FOREM NÃO ESTACIONÁRIOS?

- Até agora, discutimos a modelagem supondo as séries estacionárias.
  - Como fazer a previsão em casos não estacionários?
- Se as séries apresentarem uma tendência estocástica, trabalhamos com os dados em primeira diferença  $\{\Delta y_t\}$ .
- Conduzidas as etapas da metodologia Box-Jenkins com os dados diferenciados, e encontradas projeções para  $\Delta y_t$  fora da amostra, recompomos as projeções em nível usando o fato de que  $y_{t+1} = y_t + \Delta y_{t+1}$ .
  - Isto é, se temos  $T$  observações, projetamos  $\widehat{y_{T+1}} = y_t + \widehat{\Delta y_{T+1}}$ ,  $y_{t+2} = y_t + \widehat{\Delta y_{t+1}} + \widehat{\Delta y_{t+2}}$ , e assim por diante.



## MODELOS ARIMA(P,D,Q)

- Em outras palavras, no caso de raiz unitária, a metodologia irá estimar um modelo  $\text{ARIMA}(p,1,q)$ , da forma:

$$\Delta y_t = \alpha + \sum_{i=1}^p \beta_i \Delta y_{t-i} + \epsilon_t + \sum_{j=1}^q \theta_j \epsilon_{t-j}$$

- De modo geral, se a série é  $I(d)$ , a modelagem considerará modelos  $\text{ARIMA}(p,d,q)$ :

$$\Phi(L)(1-L)^d y_t = \alpha + \Psi(L)\epsilon_t,$$

para polinômios  $\Phi(L)$  e  $\Psi(L)$  de grau  $p$  e  $q$ , respectivamente.

## PREVISÃO COM TENDÊNCIA DETERMINÍSTICA

- Se séries apresentam tendência determinística, conduzimos a metodologia com dados *detrended*. Calculadas as projeções *detrended*, recompomos projeções em nível usando a tendência estimada.
- Por exemplo, se estimamos uma tendência linear:

$$y_t = \tilde{a} + \tilde{b}t + \tilde{\xi}_t$$

e ajustamos um modelo ARMA para  $\tilde{\xi}_t$ , a projeção para fora da amostra é:

$$\widehat{y_{T+h}} = \tilde{a} + \tilde{b}(T+h) + \widehat{\tilde{\xi}_{T+h}},$$

onde  $\widehat{\tilde{\xi}_{T+h}}$  é a projeção do ARMA para  $T+h$  (veremos como calculá-la na etapa de previsão).

- Estimação de ARMA para dado *detrended* é equivalente a estimar um modelo ARMA(p,q) com tendência determinística.

$$\Phi(L)y_t = \alpha + \gamma t + \Psi(L)\epsilon_t.$$

# “FILOSOFIA” DA METODOLOGIA DE BOX-JENKINS

- A restrição a modelos ARMA(p,q) pode ser entendida a partir do **teorema de decomposição de Wold**.
- Segundo esse teorema, **qualquer processo fracamente estacionário** pode ser representado pela soma de um MA( $\infty$ ), acrescido de uma função determinística dos  $y$  no passados:

$$y_t = \epsilon_t + \sum_{l=0}^{\infty} \psi_l \epsilon_{t-l} + \kappa_t,$$

onde  $\kappa_t$  é função “aproximadamente” linear de  $y_{t-1}$ ,  $y_{t-2}$ ...

- Ideia de Box-Jenkins é aproximar essa representação por um ARMA(p,q), com  $p$  e  $q$  **pequenos**.
  - Ideia é que aproximação **parcimoniosa**, por ser menos ruidosa, tende a funcionar melhor que modelos muito complexos.

# Identificação

## IDENTIFICAÇÃO DE UM ARMA(p,q)

- A etapa de identificação da metodologia Box-Jenkins consiste em encontrar quais modelos da classe ARMA(p,q) melhor caracterizam a série de interesse.
- A identificação consiste em analisar a função de autocorrelação (FAC) e a função de autocorrelação parcial (FACP) da série estacionária.

# FUNÇÃO DE AUTOCORRELAÇÃO SERIAL (FAC)

- A **função de autocorrelação (FAC)** de uma série  $\{Y_t\}_t$  estacionária é o mapa que associa, a cada número  $k > 0$ , a autocorrelação de ordem  $k$ , i.e.  $\gamma_k = \text{cor}(Y_t, Y_{t-k})$ .
- Note que essa função está bem definida para processos estacionários, visto que  $\text{cor}(Y_t, Y_{t-k})$  não depende de  $t$ .

$$\text{cor}(Y_t, Y_{t-k}) = \frac{\text{cov}(Y_t, Y_{t-k})}{\text{sd}(Y_t) \text{sd}(Y_{t-k})} = \frac{\text{cov}(Y_t, Y_{t-k})}{\mathbb{V}(Y_t)}$$

# FUNÇÃO DE AUTOCORRELAÇÃO SERIAL PARCIAL (FACP)

- A função de autocorrelação parcial (FACP) de uma série  $\{Y_t\}_t$  estacionária é o mapa que associa, a cada número  $k > 0$ , a correlação  $\theta_k$  entre  $Y_t$  e  $Y_{t-k}$ , controlando por  $Y_{t-1}, Y_{t-2}, \dots, Y_{t-k+1}$ .
- A autocorrelação parcial de ordem  $k$  ( $\theta_k$ ) é dada pelo coeficiente  $\tau_k$  associado a  $Y_{t-k}$  no modelo preditivo linear:

$$\begin{aligned} Y_t &= \tau_0 + \tau_1 Y_{t-1} + \tau_2 Y_{t-2} \dots + \tau_k Y_{t-k} + \nu_t \\ \mathbb{E}[\nu_t] &= 0, \mathbb{E}[\nu_t Y_{t-j}] = 0, \quad j = 1, \dots, k \end{aligned} \tag{1}$$

- Note que função está bem definida para processos estacionários, visto que coeficientes do melhor preditor linear em (1) não dependem de  $t$ .

# FAC E FACP ESTIMADAS

- Na prática, não observamos a FAC nem a FACP de um processo, mas podemos estimá-las usando as realizações da série de interesse.
  - Estimamos a FAC calculando as autocorrelações nos dados.

$$\hat{\gamma}_k = \frac{\sum_{t=1}^{T-k} (y_t - \bar{y})(y_{t+k} - \bar{y})}{\sum_{t=1}^T (y_t - \bar{y})^2},$$

onde  $\bar{y} = T^{-1} \sum_{t=1}^T y_t$ .

- Estimamos a FACP ajustando o modelo (1) aos dados.




# INFERÊNCIA SOBRE FAC E FACP POPULACIONAIS


- Como observamos apenas algumas realizações do processo, gostaríamos de testar hipóteses sobre a FAC e FACP populacionais.
- Sob algumas condições mais estridentes, o intervalo  $[-2/\sqrt{T}, 2/\sqrt{T}]$  é uma região de aceitação aproximadamente válida para o teste da nula  $\gamma_k = 0$  ( $\theta_k = 0$  na FACP) contra a alternativa bilateral ao nível de significância de 5%.
  - São esses intervalos que são apresentados, no R, quando computamos a FAC e FACP.
  - Para autocorrelações (parciais) estimadas que excedem esses limites, rejeitamos a hipótese nula de não autocorrelação (parcial) a essa ordem.

# FAC E FACP AMOSTRAIS DE $\Delta$ DESEMPREGO

Series as.numeric(diff(desemprego\_brasil))



Series as.numeric(diff(desemprego\_brasil))



# INFERÊNCIA CONJUNTA SOBRE A FAC

- Para testar a nula conjunta de que  $\gamma_1 = \gamma_2 = \dots = \gamma_s = 0$ , onde  $s$  é pequeno relativamente a  $T$ , podemos usar a estatística de Ljung-Box:

$$\hat{Q} = T(T+2) \sum_{r=1}^s \frac{\hat{\gamma}_r^2}{T-k}.$$

- Com  $T$  grande, sob a nula,  $\hat{Q}$  segue uma qui-quadrado com  $s$  graus de liberdade. Valores altos da estatística são evidência contra a nula, i.e. evidência de que ao menos uma autocorrelação entre as testadas é diferente de zero.

## FAC E FACP DE UM AR(p) ESTACIONÁRIO

- Como vimos em aula anterior, a FAC de um AR(1) estacionário é dada por:

$$\gamma_k = \text{cor}(Y_t, Y_{t-k}) = \beta_1^k, \quad |\beta_1| < 1 \quad (2)$$



isto é, a FAC apresenta decaimento geométrico em direção a zero.

- De modo geral, a FAC de um AR(p) estacionário apresenta **decaimento em direção a zero**, visto que um AR(p) estacionário pode ser escrito como um MA( $\infty$ ), i.e.

$$Y_t = \mu + \epsilon_t + \sum_{j=1}^{\infty} \omega_j \epsilon_{t-j} \quad (3)$$

- E a FACP de um AR(p) estacionário? Pela definição da FACP de ordem  $k$  como o coeficiente de  $Y_{t-k}$  na regressão populacional de  $Y_t$  em  $Y_{t-1}, Y_{t-2}, \dots, Y_{t-k}$ , esperamos que a FACP seja **truncada em  $p$** , visto que o processo só depende diretamente das  $p$  primeiras defasagens.



# EXEMPLO: FAC E FACP ESTIMADAS DE UM AR(2) ( $T=10.000$ )



## FAC E FACP DE UM $MA(q)$ INVERTÍVEL

- Como vimos em aula anterior, a FAC de um  $MA(q)$  é **truncada** em  $q$ , visto que a correlação morre após  $q$  períodos.
- E a FACP? Se o processo  $MA$  for invertível, vimos que ele pode ser escrito como um  $AR(\infty)$ . Dessa representação, fica claro que a FACP de um  $MA(q)$  apresenta **decaimento em direção a zero**.

# EXEMPLO: FAC E FACP ESTIMADAS DE UM MA(3) ( $T=10.000$ )




## FAC E FACP DE UM ARMA(p,q) ESTACIONÁRIO E INVERTÍVEL

- Generalizando a discussão anterior, um ARMA(p,q) estacionário cuja parte MA é invertível pode ser representado tanto como um  $AR(\infty)$  como um  $MA(\infty)$ . Nesse caso, tanto a FAC como a FACP apresentam decaimento.
- Nesses casos, costuma-se considerar a ordem máxima  $q_{\max}$  em que a FAC torna-se pouco significativa e a ordem  $p_{\max}$  em que a FACP torna-se pouco significativa e considerar todos os ARMA(p,q),  $0 \leq p \leq p_{\max}$  e  $0 \leq q \leq q_{\max}$  como candidatos.




# EXEMPLO: FAC E FACP ESTIMADAS DE UM ARMA(2,3) (T=10.000)

Series arma23



Series arma23



# RESUMO

Modelo	FAC	FACP
AR( $p$ ) estacionário	decai	truncada em $p$
MA( $q$ ) invertível	truncada em $q$	decai
ARMA( $p, q$ ) estacionário e invertível	decai (esp. após $q$ )	decai (esp. após $p$ )

# Estimação

# ESTIMAÇÃO CONDICIONAL VS. INCONDICIONAL

- Para a estimação de modelos  $\text{ARMA}(p,q)$ , há duas abordagens de estimação.
  - Na abordagem **condicional**, não utilizamos a informação acerca da distribuição das primeiras observações na estimação.
  - Na abordagem **incondicional**, fazemos hipóteses adicionais sobre a distribuição do ruído branco, que nos permitem incorporar a distribuição das primeiras observações na análise.
- Computacionalmente, a abordagem condicional é mais simples, embora menos eficiente que a segunda.
- Embora a abordagem incondicional aparente requerer mais hipóteses, visto que especificamos a distribuição do ruído branco, a estimação é robusta a violações dessa hipótese quando o número de observações é grande (“pseudo” máxima verossimilhança).

# ESTIMAÇÃO CONDICIONAL DO $AR(p)$

conteúdo...

# ESTIMAÇÃO CONDICIONAL DO ARMA( $p,q$ )

conteúdo...

# ESTIMAÇÃO INCONDICIONAL DO ARMA( $p,q$ )

conteúdo...