

# EAE1223: ECONOMETRIA III

## AULA 6 - MODELOS VETORIAIS AUTORREGRESSIVOS

Luis A. F. Alvarez

25 de abril de 2024

# VETORES ALEATÓRIOS E MATRIZ DE VARIÂNCIA-COVARIÂNCIA

- Um vetor (coluna) aleatório  $\mathbf{X}$ , com valores em  $\mathbb{R}^d$ , é uma função com domínio no espaço de probabilidade  $(\Omega, \Sigma, \mathbb{P})$  e contradomínio em  $\mathbb{R}^d$ .
  - Posto de outra forma, um vetor aleatório  $\mathbf{X}$  é um vetor cujas entradas  $\mathbf{X}_j, j = 1 \dots, d$ , são variáveis aleatórias com valores reais.
- Para um vetor aleatório  $\mathbf{X}$ , a matriz de variância-covariância,  $\mathbb{V}[\mathbf{X}]$ , é definida como:

$$\mathbb{V}[\mathbf{X}] = \mathbb{E}[\mathbf{X}\mathbf{X}'] - \mathbb{E}[\mathbf{X}]\mathbb{E}[\mathbf{X}']$$

- Matriz de variância-covariância é  $d \times d$ , simétrica, positiva semidefinida, com entrada  $(i, j)$  iguais a:

$$\mathbb{V}[\mathbf{X}]_{i,j} = \text{cov}(\mathbf{X}_i, \mathbf{X}_j) .$$

# MATRIZ DE COVARIÂNCIA ENTRE DOIS VETORES ALEATÓRIOS

- Seja  $\mathbf{X}$  um vetor aleatório em  $\mathbb{R}^d$ , e  $\mathbf{Y}$  um vetor aleatório em  $\mathbb{R}^p$ , definimos a matriz de covariância entre  $\mathbb{V}[\mathbf{X}]$  e  $\mathbf{Y}$  como:

$$\text{cov}(\mathbf{X}, \mathbf{Y}) = \mathbb{E}[\mathbf{X}\mathbf{Y}'] - \mathbb{E}[\mathbf{X}]\mathbb{E}[\mathbf{Y}'].$$

- Matriz  $d \times p$  em que a entrada  $(i, j)$  é igual a:

$$\text{cov}(\mathbf{X}, \mathbf{Y})_{i,j} = \text{cov}(\mathbf{X}_i, \mathbf{Y}_j)$$

## PROCESSO VETORIAL FRACAMENTE ESTACIONÁRIO

- Um processo estocástico vetorial é uma coleção de vetores aleatórios definidos em  $\mathbb{R}^d$ , indexados por um conjunto  $\mathcal{I}$ , isto é  $\{\mathbf{X}_t : t \in \mathcal{I}\}$ , onde cada  $\mathbf{X}_t$  é vetor aleatório em  $\mathbb{R}^d$ .
  - Cada entrada  $j = 1 \dots d$  define um processo estocástico com valores reais  $\{\mathbf{X}_{j,t} : t \in \mathcal{I}\}$  descrevendo a evolução da  $j$ -ésima entrada ao longo de  $\mathcal{I}$ .
- Um processo estocástico vetorial  $\{\mathbf{X}_t : t \in \mathcal{T}\}$  indexado no tempo  $\mathcal{T}$  é dito fracamente estacionário se:
  1.  $\mathbb{E}[\mathbf{X}_t] = \boldsymbol{\mu}$  para todo  $t \in \mathcal{T}$ .
  2.  $\mathbb{V}[\mathbf{X}_t] = \boldsymbol{\Sigma}_0$  para todo  $t \in \mathcal{T}$ , com  $\text{tr}(\boldsymbol{\Sigma}_0) < \infty$ .
  3.  $\text{cov}(\mathbf{X}_t, \mathbf{X}_{t-h}) = \boldsymbol{\Sigma}_h$ , para todo  $t \in \mathcal{T}$ ,  $h \in \mathcal{N}$ .
- Extensão do conceito de série de tempo estacionária para o caso vetorial.
- Pedimos estabilidade das covariâncias contemporâneas e extemporâneas entre as entradas dos vetores.
- **Obs:** se processo vetorial é fracamente estacionário, cada uma das entradas  $\{\mathbf{X}_{j,t} : t \in \mathcal{T}\}$ ,  $j = 1, \dots, d$ , é fracamente estacionária.


# RUÍDO BRANCO VETORIAL

- Um processo estocástico vetorial  $\{\mathbf{X}_t : t \in \mathcal{T}\}$  com valores em  $\mathbb{R}^d$  é dito um ruído branco vetorial se:
  - $\mathbb{E}[\mathbf{X}_t] = \mathbf{0}_{d \times 1}$ , para todo  $t \in \mathcal{T}$ .
  - $\mathbb{V}[\mathbf{X}_t] = \Sigma_0$  para todo  $t \in \mathcal{T}$ , com  $\text{tr}(\Sigma_0) < \infty$ .
  - $\text{cov}(\mathbf{X}_t, \mathbf{X}_l) = \mathbf{0}_{d \times d}$ , para todo  $t \neq l$ .
- No ruído branco vetorial, permitimos associação contemporânea entre as entradas do vetor, mas não há nem autodependência nem dependência cruzada entre as entradas no tempo.

# RUÍDO BRANCO VETORIAL GAUSSIANO

$$\begin{pmatrix} \epsilon_{1,t} \\ \epsilon_{2,t} \end{pmatrix} \stackrel{\text{iid}}{\sim} \mathcal{N} \left( \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & 1 \\ 1 & 2 \end{pmatrix} \right)$$

**rb**



# MODELOS VETORIAIS AUTORREGRESSIVOS

- Considere  $d$  séries de tempo  $\{X_{j,t} : t \in \mathbb{Z}\}$ ,  $j = 1, \dots, d$ .
- Dizemos que estas séries definem um processo vetorial autorregressivo de ordem  $p$ , ou VAR( $p$ ), se, para todo  $j = 1, \dots, d$  e  $t \in \mathbb{Z}$ :

$$\begin{aligned} X_{j,t} &= a_{j,0} + \sum_{l=1}^p a_{j,1,l} X_{1,t-l} + \sum_{l=1}^p a_{j,2,l} X_{2,t-l} + \dots + \sum_{l=1}^p a_{j,d,l} X_{d,t-l} + \epsilon_{j,t} \\ &= a_{j,0} + \sum_{k=1}^d \sum_{l=1}^p a_{j,k,l} X_{k,t-l} + \epsilon_{j,t}, \end{aligned}$$

onde  $\epsilon_t = (\epsilon_{1,t}, \epsilon_{2,t}, \dots, \epsilon_{d,t})'$  é um ruído branco vetorial.

- No VAR( $p$ ), assim como no AR( $p$ ), evolução em cada uma das  $d$  variáveis depende do que ocorreu nela mesma nos últimos  $p$  períodos.
- Mas além disso, trajetória depende do que ocorreu nos últimos  $p$  períodos **nas demais variáveis**.
- Série depende também de uma inovação  $\epsilon_{j,t}$ , imprevisível com base no passado, mas que pode estar contemporaneamente associada às demais inovações nas outras equações (choques comuns).

## VAR(p) EM NOTAÇÃO VETORIAL

- Um VAR(p) pode ser escrito, compactamente, em notação vetorial.
- De fato, definindo  $\mathbf{X}_t = (X_{1,t}, X_{2,t}, \dots, X_{d,t})'$ , podemos escrever o sistema como

$$\mathbf{X}_t = \mathbf{a}_0 + \mathbf{A}_1 \mathbf{X}_{t-1} + \mathbf{A}_2 \mathbf{X}_{t-2} + \dots + \mathbf{A}_p \mathbf{X}_{t-p} + \boldsymbol{\epsilon}_t,$$

onde

$$\mathbf{a}_0 = \begin{bmatrix} a_{1,0} \\ a_{2,0} \\ \vdots \\ a_{d,0} \end{bmatrix} \quad \mathbf{A}_l = \begin{bmatrix} a_{1,1,l} & a_{1,2,l} & \dots & a_{1,d,l} \\ a_{2,1,l} & a_{2,2,l} & \dots & a_{2,d,l} \\ \vdots & \vdots & \dots & \vdots \\ a_{d,1,l} & a_{d,2,l} & \dots & a_{d,d,l} \end{bmatrix}$$



## VAR(p) ESTACIONÁRIO

- Um VAR(p) é dito estacionário se o processo vetorial resultante é estacionário.
- Condição para estacionariedade do VAR(p) é que:

$$|z| \leq 1 \implies \det(\mathbb{I}_{d \times d} - \mathbf{A}_1 z - \mathbf{A}_2 z^2 \dots - \mathbf{A}_p z^p) \neq 0$$

- Todas as raízes do polinômio  $\phi(z) = \det(\mathbb{I}_{d \times d} - \mathbf{A}_1 z - \mathbf{A}_2 z^2 \dots - \mathbf{A}_p z^p)$  devem se encontrar fora do círculo unitário.
- Nesta aula, focaremos na estimação de VAR(p) estacionários.
  - Portanto, cada uma das séries deverá estar devidamente estacionarizada.

# ESTIMAÇÃO DO VAR(p)

- Dado um painel com observações de  $d$  séries durante  $T$  períodos,  $\{\mathbf{X}_{j,t}\}_{t=1}^T$ , como estimar os parâmetros de um VAR(p)?
- Maneira mais simples é estimar os parâmetros através de MQO, **equação a equação**.
- Isto é, estimamos os parâmetros da  $j$ -ésima equação resolvendo:

$$\min_{b_{0,j}, \{b_{j,k,l}\}_{k,l}} \sum_{t=p+1}^T \left( \mathbf{x}_{j,t} - b_{0,j} - \sum_{k=1}^d \sum_{l=1}^p b_{j,k,l} \mathbf{x}_{j,t-l} \right)^2$$

- Para cada equação, rodamos uma regressão com  $T$  observações e  $p \times d + 1$  parâmetros.

# SUR

- A estimação dos parâmetros de um VAR por MQO, equação a equação, é potencialmente ineficiente.
- Isso se deve ao fato de que os choques em uma equação  $j$ , por serem (potencialmente) contemporaneamente correlacionados com os choques das demais equações, podem conter informação relevante para estimar os parâmetros de outras equações
  - Erro em uma equação é informativo sobre a outra equação.
- Seja  $\hat{\Sigma}_0$  um estimador preliminar de  $\mathbb{V}(\epsilon_t)$ .
  - Por exemplo, estimador da variância-covariância com base nos resíduos do estimador de MQO equação a equação.
- O estimador de *seemingly unrelated regression* (SUR) dos parâmetros de um VAR propõe-se a estimar os parâmetros do sistema conjuntamente, minimizando:

$$\min_{b_0, B_1, \dots, B_p} \sum_{t=p+1}^T \left( \mathbf{X}_t - \mathbf{b}_0 - \sum_{l=1}^p \mathbf{B}_l \mathbf{X}_{t-l} \right)' \hat{\Sigma}^{-1} \left( \mathbf{X}_t - \mathbf{b}_0 - \sum_{l=1}^p \mathbf{B}_l \mathbf{X}_{t-l} \right)$$

# MÁXIMA VEROSSIMILHANÇA CONDICIONAL

- Sob a hipótese auxiliar:

$$\epsilon_t \stackrel{iid}{\sim} N(\mathbf{0}_{d \times 1}, \Sigma_0)$$

podemos calcular a verossimilhança de  $\mathbf{X}_{t+p+1}, \dots, \mathbf{X}_T$ , condicional a  $\mathbf{X}_1, \dots, \mathbf{X}_p$ .

- Estimador de máxima verossimilhança condicional estima **simultaneamente**  $\mathbf{a}_0$ , os  $\mathbf{A}_l$  e  $\Sigma_0$ .

# RELAÇÃO ENTRE OS MÉTODOS DE ESTIMAÇÃO

- Se o espaço de parâmetros é irrestrito, no sentido de que os parâmetros  $\mathbf{a}_0$  e os  $\mathbf{A}_I$  podem tomar qualquer valor real, os estimadores de MQO equação a equação, SUR, e máxima verossimilhança condicional são numericamente iguais.
- Se impomos restrições nos parâmetros  $\mathbf{a}_0$  e os  $\mathbf{A}_I$ , estimador de MQO equação a equação é consistente, embora SUR e máxima verossimilhança condicional sejam mais eficientes.
- Se, além disso, impomos restrições na matriz  $\Sigma_0$ , os três estimadores são consistentes, mas máxima verossimilhança condicional é o mais eficiente.

## SELECIONANDO A ORDEM $p$ DE UM VAR

- Para selecionar a ordem  $p$  de um VAR, podemos adotar generalizações dos critérios de informação vistos para modelos multivariados:

$$\text{AIC}(p) = \ln(\det(\hat{\Sigma}(p))) + \frac{2}{T}(d^2p + d),$$

$$\text{HQ}(p) = \ln(\det(\hat{\Sigma}(p))) + \frac{2 \log \log(T)}{T}(d^2p + d),$$

$$\text{SC}(p) = \ln(\det(\hat{\Sigma}(p))) + \frac{\log(T)}{T}(d^2p + d),$$

onde  $\hat{\Sigma}(p)$  é a matriz de variância-covariância dos resíduos do modelo VAR estimado com  $p$  defasagens.

- Métodos oferecem aproximações ao erro quadrático médio de previsão um passo à frente, corrigidas do viés induzido por *overfitting*.

## TESTANDO A INCLUSÃO DE DEFASAGENS

- Partindo de um VAR(p). Podemos testar se há necessidade de incluir a  $p$ -ésima defasagem.
- Especificamente, gostaríamos de testar.

$$H_0 : \mathbf{A}_p = \mathbf{0}_{d \times d} \quad H_1 : \mathbf{A}_p \neq \mathbf{0}_{d \times d} \quad (1)$$

- Teste pode ser conduzido através da estatística de razão de verossimilhança.

$$LR = 2 \cdot (\hat{L}_p - \hat{L}_{p-1}) \quad (2)$$

onde  $\hat{L}_j$  é a log-verossimilhança maximizada do estimador de máxima verossimilhança condicional, do modelo que inclui  $j$  defasagens.

- Sob hipótese nula, com  $T$  grande, estatística segue distribuição qui-quadrado com  $d^2$  graus de liberdade.

# DIAGNÓSTICO DOS RESÍDUOS

- Escolhida uma ordem  $p$  do VAR, podemos avaliar o comportamento dos erros.
- Em particular, para  $h \in \mathbb{N}$ , podemos testar a hipótese nula:

$$H_0 : \text{cov}(\epsilon_t, \epsilon_{t-j}) = \mathbf{0}_{d \times d}, \quad j = 1, \dots, h.$$

usando um análogo vetorial do teste de Ljung-Box.

- A esse teste, damos o nome de Portmanteau.
- Também é possível estudar a normalidade conjunta dos erros, através de um análogo vetorial do teste de Jarque-Bera.



## INCLUSÃO DE COMPONENTES DETERMINÍSTICOS

- No modelo VAR apresentado, incluímos tão somente um intercepto entre os componentes determinísticos.
- Para séries *trend stationary*, devemos fazer o *detrending* dos dados para a estimação do VAR estacionário.
- Se todas as séries apresentam tendência, um jeito mais eficiente de fazer isso é estimar conjuntamente a tendência ao VAR, ajustando o modelo:

$$\mathbf{X}_t = \mathbf{a}_0 + \mathbf{a}_1 t + \mathbf{A}_1 \mathbf{X}_{t-1} + \mathbf{A}_2 \mathbf{X}_{t-2} + \dots + \mathbf{A}_p \mathbf{X}_{t-p} + \epsilon_t,$$

- Se há evidência de sazonalidade nas séries, podemos ajustar o VAR incluindo um conjunto de *dummies* sazonais.

$$\mathbf{X}_t = \mathbf{a}_0 + \gamma \mathbf{d}_t + \mathbf{A}_1 \mathbf{X}_{t-1} + \mathbf{A}_2 \mathbf{X}_{t-2} + \dots + \mathbf{A}_p \mathbf{X}_{t-p} + \epsilon_t,$$

# PREVISÃO

- Assim como nos modelos ARMA, a previsão em um modelo VAR se faz de maneira recursiva

# REFERÊNCIAS