

# EAE1223: ECONOMETRIA III

## AULA 6 - MODELOS VETORIAIS AUTORREGRESSIVOS

Luis A. F. Alvarez

29 de abril de 2024

# VETORES ALEATÓRIOS E MATRIZ DE VARIÂNCIA-COVARIÂNCIA

- Um vetor (coluna) aleatório  $\mathbf{X}$ , com valores em  $\mathbb{R}^d$ , é uma função com domínio no espaço de probabilidade  $(\Omega, \Sigma, \mathbb{P})$  e contradomínio em  $\mathbb{R}^d$ .
  - Posto de outra forma, um vetor aleatório  $\mathbf{X}$  é um vetor cujas entradas  $\mathbf{X}_j, j = 1 \dots, d$ , são variáveis aleatórias com valores reais.
- Para um vetor aleatório  $\mathbf{X}$ , a matriz de variância-covariância,  $\mathbb{V}[\mathbf{X}]$ , é definida como:

$$\mathbb{V}[\mathbf{X}] = \mathbb{E}[\mathbf{X}\mathbf{X}'] - \mathbb{E}[\mathbf{X}]\mathbb{E}[\mathbf{X}']$$

- Matriz de variância-covariância é  $d \times d$ , simétrica, positiva semidefinida, com entrada  $(i, j)$  iguais a:

$$\mathbb{V}[\mathbf{X}]_{i,j} = \text{cov}(\mathbf{X}_i, \mathbf{X}_j) .$$

# MATRIZ DE COVARIÂNCIA ENTRE DOIS VETORES ALEATÓRIOS

- Seja  $\mathbf{X}$  um vetor aleatório em  $\mathbb{R}^d$ , e  $\mathbf{Y}$  um vetor aleatório em  $\mathbb{R}^p$ , definimos a matriz de covariância entre  $\mathbb{V}[\mathbf{X}]$  e  $\mathbf{Y}$  como:

$$\text{cov}(\mathbf{X}, \mathbf{Y}) = \mathbb{E}[\mathbf{X}\mathbf{Y}'] - \mathbb{E}[\mathbf{X}]\mathbb{E}[\mathbf{Y}'].$$

- Matriz  $d \times p$  em que a entrada  $(i, j)$  é igual a:

$$\text{cov}(\mathbf{X}, \mathbf{Y})_{i,j} = \text{cov}(\mathbf{X}_i, \mathbf{Y}_j)$$

# PROCESSO VETORIAL FRACAMENTE ESTACIONÁRIO

- Um processo estocástico vetorial é uma coleção de vetores aleatórios definidos em  $\mathbb{R}^d$ , indexados por um conjunto  $\mathcal{I}$ , isto é  $\{\mathbf{X}_t : t \in \mathcal{I}\}$ , onde cada  $\mathbf{X}_t$  é vetor aleatório em  $\mathbb{R}^d$ .
  - Cada entrada  $j = 1 \dots d$  define um processo estocástico com valores reais  $\{\mathbf{X}_{j,t} : t \in \mathcal{I}\}$  descrevendo a evolução da  $j$ -ésima entrada ao longo de  $\mathcal{I}$ .
- Um processo estocástico vetorial  $\{\mathbf{X}_t : t \in \mathcal{T}\}$  indexado no tempo  $\mathcal{T}$  é dito fracamente estacionário se:
  1.  $\mathbb{E}[\mathbf{X}_t] = \boldsymbol{\mu}$  para todo  $t \in \mathcal{T}$ .
  2.  $\mathbb{V}[\mathbf{X}_t] = \boldsymbol{\Sigma}_0$  para todo  $t \in \mathcal{T}$ , com  $\text{tr}(\boldsymbol{\Sigma}_0) < \infty$ .
  3.  $\text{cov}(\mathbf{X}_t, \mathbf{X}_{t-h}) = \boldsymbol{\Sigma}_h$ , para todo  $t \in \mathcal{T}$ ,  $h \in \mathcal{N}$ .
- Extensão do conceito de série de tempo estacionária para o caso vetorial.
- Pedimos estabilidade das covariâncias contemporâneas e extemporâneas entre as entradas dos vetores.
- **Obs:** se processo vetorial é fracamente estacionário, cada uma das entradas  $\{\mathbf{X}_{j,t} : t \in \mathcal{T}\}$ ,  $j = 1, \dots, d$ , é fracamente estacionária.


# RUÍDO BRANCO VETORIAL

- Um processo estocástico vetorial  $\{\mathbf{X}_t : t \in \mathcal{T}\}$  com valores em  $\mathbb{R}^d$  é dito um ruído branco vetorial se:
  - $\mathbb{E}[\mathbf{X}_t] = \mathbf{0}_{d \times 1}$ , para todo  $t \in \mathcal{T}$ .
  - $\mathbb{V}[\mathbf{X}_t] = \Sigma_0$  para todo  $t \in \mathcal{T}$ , com  $\text{tr}(\Sigma_0) < \infty$ .
  - $\text{cov}(\mathbf{X}_t, \mathbf{X}_l) = \mathbf{0}_{d \times d}$ , para todo  $t \neq l$ .
- No ruído branco vetorial, permitimos associação contemporânea entre as entradas do vetor, mas não há nem autodependência nem dependência cruzada entre as entradas no tempo.

# RUÍDO BRANCO VETORIAL GAUSSIANO

$$\begin{pmatrix} \epsilon_{1,t} \\ \epsilon_{2,t} \end{pmatrix} \stackrel{\text{iid}}{\sim} \mathcal{N} \left( \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & 1 \\ 1 & 2 \end{pmatrix} \right)$$

**rb**



# MODELOS VETORIAIS AUTORREGRESSIVOS

- Considere  $d$  séries de tempo  $\{X_{j,t} : t \in \mathbb{Z}\}$ ,  $j = 1, \dots, d$ .
- Dizemos que estas séries definem um processo vetorial autorregressivo de ordem  $p$ , ou VAR( $p$ ), se, para todo  $j = 1, \dots, d$  e  $t \in \mathbb{Z}$ :

$$\begin{aligned} X_{j,t} &= a_{j,0} + \sum_{l=1}^p a_{j,1,l} X_{1,t-l} + \sum_{l=1}^p a_{j,2,l} X_{2,t-l} + \dots + \sum_{l=1}^p a_{j,d,l} X_{d,t-l} + \epsilon_{j,t} \\ &= a_{j,0} + \sum_{k=1}^d \sum_{l=1}^p a_{j,k,l} X_{k,t-l} + \epsilon_{j,t}, \end{aligned}$$

onde  $\epsilon_t = (\epsilon_{1,t}, \epsilon_{2,t}, \dots, \epsilon_{d,t})'$  é um ruído branco vetorial.

- No VAR( $p$ ), assim como no AR( $p$ ), evolução em cada uma das  $d$  variáveis depende do que ocorreu nela mesma nos últimos  $p$  períodos.
- Mas além disso, trajetória depende do que ocorreu nos últimos  $p$  períodos **nas demais variáveis**.
- Série depende também de uma inovação  $\epsilon_{j,t}$ , imprevisível com base no passado, mas que pode estar contemporaneamente associada às demais inovações nas outras equações (choques comuns).

## VAR(p) EM NOTAÇÃO VETORIAL

- Um VAR(p) pode ser escrito, compactamente, em notação vetorial.
- De fato, definindo  $\mathbf{X}_t = (X_{1,t}, X_{2,t}, \dots, X_{d,t})'$ , podemos escrever o sistema como

$$\mathbf{X}_t = \mathbf{a}_0 + \mathbf{A}_1 \mathbf{X}_{t-1} + \mathbf{A}_2 \mathbf{X}_{t-2} + \dots + \mathbf{A}_p \mathbf{X}_{t-p} + \boldsymbol{\epsilon}_t,$$

onde

$$\mathbf{a}_0 = \begin{bmatrix} a_{1,0} \\ a_{2,0} \\ \vdots \\ a_{d,0} \end{bmatrix} \quad \mathbf{A}_l = \begin{bmatrix} a_{1,1,l} & a_{1,2,l} & \dots & a_{1,d,l} \\ a_{2,1,l} & a_{2,2,l} & \dots & a_{2,d,l} \\ \vdots & \vdots & \dots & \vdots \\ a_{d,1,l} & a_{d,2,l} & \dots & a_{d,d,l} \end{bmatrix}$$



## VAR(p) ESTACIONÁRIO

- Um VAR(p) é dito estacionário se o processo vetorial resultante é estacionário.
- Condição para estacionariedade do VAR(p) é que:

$$|z| \leq 1 \implies \det(\mathbb{I}_{d \times d} - \mathbf{A}_1 z - \mathbf{A}_2 z^2 \dots - \mathbf{A}_p z^p) \neq 0$$

- Todas as raízes do polinômio  $\phi(z) = \det(\mathbb{I}_{d \times d} - \mathbf{A}_1 z - \mathbf{A}_2 z^2 \dots - \mathbf{A}_p z^p)$  devem se encontrar fora do círculo unitário.
- Nesta aula, focaremos na estimação de VAR(p) estacionários.
  - Portanto, cada uma das séries deverá estar devidamente estacionarizada.

# ESTIMAÇÃO DO VAR(p)

- Dado um painel com observações de  $d$  séries durante  $T$  períodos,  $\{\mathbf{X}_{j,t}\}_{t=1}^T$ ,  $j = 1, \dots, d$ , como estimar os parâmetros de um VAR(p)?
- Maneira mais simples é estimar os parâmetros através de MQO, equação a equação.
- Isto é, estimamos os parâmetros da  $j$ -ésima equação resolvendo:

$$\min_{b_{0,j}, \{b_{j,k,l}\}_{k,l}} \sum_{t=p+1}^T \left( \mathbf{X}_{j,t} - b_{0,j} - \sum_{k=1}^d \sum_{l=1}^p b_{j,k,l} X_{k,t-l} \right)^2$$

- Para cada equação, rodamos uma regressão com  $T$  observações e  $p \times d + 1$  parâmetros.

# SUR

- A estimação dos parâmetros de um VAR por MQO, equação a equação, é potencialmente ineficiente.
- Isso se deve ao fato de que os choques em uma equação  $j$ , por serem (potencialmente) contemporaneamente correlacionados com os choques das demais equações, podem conter informação relevante para estimar os parâmetros de outras equações
  - Erro em uma equação é informativo sobre a outra equação.
- Seja  $\hat{\Sigma}_0$  um estimador preliminar de  $\mathbb{V}(\epsilon_t)$ .
  - Por exemplo, estimador da variância-covariância com base nos resíduos do estimador de MQO equação a equação.
- O estimador de *seemingly unrelated regression* (SUR) dos parâmetros de um VAR propõe-se a estimar os parâmetros do sistema conjuntamente, minimizando:

$$\min_{b_0, B_1, \dots, B_p} \sum_{t=p+1}^T \left( \mathbf{X}_t - \mathbf{b}_0 - \sum_{l=1}^p \mathbf{B}_l \mathbf{X}_{t-l} \right)' \hat{\Sigma}_0^{-1} \left( \mathbf{X}_t - \mathbf{b}_0 - \sum_{l=1}^p \mathbf{B}_l \mathbf{X}_{t-l} \right)$$

# MÁXIMA VEROSSIMILHANÇA CONDICIONAL

- Sob a hipótese auxiliar:

$$\epsilon_t \stackrel{iid}{\sim} N(\mathbf{0}_{d \times 1}, \Sigma_0)$$

podemos calcular a verossimilhança de  $\mathbf{X}_{p+1}, \dots, \mathbf{X}_T$ , condicional a  $\mathbf{X}_1, \dots, \mathbf{X}_p$ .

- Estimador de máxima verossimilhança condicional estima **simultaneamente**  $\mathbf{a}_0$ , os  $\mathbf{A}_l$  e  $\Sigma_0$ .

# RELAÇÃO ENTRE OS MÉTODOS DE ESTIMAÇÃO

- Se o espaço de parâmetros é irrestrito, no sentido de que os parâmetros  $\mathbf{a}_0$  e os  $\mathbf{A}_I$  podem tomar qualquer valor real, os estimadores de MQO equação a equação, SUR, e máxima verossimilhança condicional são numericamente iguais.
- Se impomos restrições nos parâmetros  $\mathbf{a}_0$  e os  $\mathbf{A}_I$ , estimador de MQO equação a equação é consistente, embora SUR e máxima verossimilhança condicional sejam mais eficientes.
- Se, além disso, impomos restrições na matriz  $\Sigma_0$ , os três estimadores são consistentes, mas máxima verossimilhança condicional é o mais eficiente.

## SELECIONANDO A ORDEM $p$ DE UM VAR

- Para selecionar a ordem  $p$  de um VAR, podemos adotar generalizações multivariadas dos critérios de informação vistos para modelos univariados:

$$AIC(p) = \ln(\det(\hat{\Sigma}(p))) + \frac{2}{T}(d^2p + d),$$

$$HQ(p) = \ln(\det(\hat{\Sigma}(p))) + \frac{2 \log \log(T)}{T}(d^2p + d),$$

$$SC(p) = \ln(\det(\hat{\Sigma}(p))) + \frac{\log(T)}{T}(d^2p + d),$$

onde  $\hat{\Sigma}(p)$  é a matriz de variância-covariância dos resíduos do modelo VAR estimado com  $p$  defasagens.

- Assim como no caso univariado, no cálculo dos diferentes  $\hat{\Sigma}(p)$ , usamos os resíduos dos mesmos  $T - p_{max}$  períodos, onde  $p_{max}$  é a ordem máxima a se testar.
- Métodos oferecem aproximações ao erro quadrático médio de previsão um passo à frente, corrigidas do viés induzido por *overfitting*.

## TESTANDO A INCLUSÃO DE DEFASAGENS

- Partindo de um VAR(p), podemos testar se há necessidade de incluir a  $p$ -ésima defasagem.
- Especificamente, gostaríamos de testar.

$$H_0 : \mathbf{A}_p = \mathbf{0}_{d \times d} \quad H_1 : \mathbf{A}_p \neq \mathbf{0}_{d \times d} \quad (1)$$

- Teste pode ser conduzido através da estatística de razão de verossimilhança.

$$LR = 2 \cdot (\hat{L}_p - \hat{L}_{p-1}) \quad (2)$$

onde  $\hat{L}_j$  é a log-verossimilhança maximizada do estimador de máxima verossimilhança condicional, do modelo que inclui  $j$  defasagens.

- Sob hipótese nula, com  $T$  grande, estatística segue distribuição qui-quadrado com  $d^2$  graus de liberdade.

# DIAGNÓSTICO DOS RESÍDUOS

- Escolhida uma ordem  $p$  do VAR, podemos avaliar o comportamento dos erros.
- Em particular, para  $h \in \mathbb{N}$ , podemos testar a hipótese nula:

$$H_0 : \text{cov}(\epsilon_t, \epsilon_{t-j}) = \mathbf{0}_{d \times d}, \quad j = 1, \dots, h.$$

usando um análogo vetorial do teste de Ljung-Box.

- A esse teste, damos o nome de **Portmanteau**.
- Também é possível estudar a normalidade conjunta dos erros, através de um análogo vetorial do teste de Jarque-Bera.
  - Preocupação usualmente secundária. Normalidade garante que o MLE condicional domine outros estimadores condicionais, para além do MQO equação a equação e SUR. Também é importante na construção de intervalos de predição, assim como nos ARMA.



## INCLUSÃO DE COMPONENTES DETERMINÍSTICOS

- No modelo VAR apresentado, incluímos tão somente um intercepto entre os componentes determinísticos.
- Para séries *trend stationary*, devemos fazer o *detrending* dos dados para a estimação do VAR estacionário.
- Se todas as séries apresentam tendência, um jeito mais eficiente de fazer isso é estimar conjuntamente a tendência ao VAR, ajustando o modelo:

$$\mathbf{X}_t = \mathbf{a}_0 + \mathbf{a}_1 t + \mathbf{A}_1 \mathbf{X}_{t-1} + \mathbf{A}_2 \mathbf{X}_{t-2} + \dots + \mathbf{A}_p \mathbf{X}_{t-p} + \epsilon_t,$$

- Se há evidência de sazonalidade nas séries, podemos ajustar o VAR incluindo um conjunto de *dummies* sazonais.

$$\mathbf{X}_t = \mathbf{a}_0 + \gamma \mathbf{d}_t + \mathbf{A}_1 \mathbf{X}_{t-1} + \mathbf{A}_2 \mathbf{X}_{t-2} + \dots + \mathbf{A}_p \mathbf{X}_{t-p} + \epsilon_t,$$

## PREVISÃO FORA DA AMOSTRA

- Assim como nos modelos ARMA, a previsão em um modelo VAR se faz de maneira recursiva.
- Dados estimadores dos parâmetros do VAR, previsão um passo à frente de  $\mathbf{X}_{T+1}$  é dada por:

$$\hat{\mathbf{X}}_{T+1} = \hat{\mathbf{a}}_0 + \hat{\mathbf{A}}_1 \mathbf{X}_T + \hat{\mathbf{A}}_2 \mathbf{X}_{T-1} + \dots + \hat{\mathbf{A}}_p \mathbf{X}_{T+1-p}$$

- A previsão dois passos à frente é dada por:

$$\hat{\mathbf{X}}_{T+2} = \hat{\mathbf{a}}_0 + \hat{\mathbf{A}}_1 \hat{\mathbf{X}}_{T+1} + \hat{\mathbf{A}}_2 \mathbf{X}_T + \dots + \hat{\mathbf{A}}_p \mathbf{X}_{T+2-p},$$

e assim recursivamente.

- Previsões do VAR estacionário convergem para média incondicional estimada do processo:

$$\lim_{h \rightarrow \infty} \hat{\mathbf{X}}_{T+h} = (\mathbb{I} - \hat{\mathbf{A}}_1 - \hat{\mathbf{A}}_2 \dots - \hat{\mathbf{A}}_p)^{-1} \hat{\mathbf{a}}_0$$

## PREVISÃO ONLINE

- Em diversas situações, a previsão em tempo real ocorre num cenário em que as divulgações dos valores mais recentes das variáveis ocorrem com defasagem no tempo.
  - Dados para taxa inflação em  $T + 1$  são divulgados em um certo dia do mês  $T + 2$ , enquanto dados da SELIC média de um mês podem ser obtidas antes, a depender do calendário do COPOM.
- Nessas janelas intermediárias, em que alguns dados de  $T + 1$  já foram divulgados, mas faltam outros, é interessante entender como calcular as previsões para as variáveis que ainda não foram divulgadas para  $T + 1$ , mas incorporando **toda** a informação disponível
  - Se as defasagens entre divulgações forem muito longas e com um padrão bem-definido, uma possível solução, do ponto de vista preditivo, é trabalhar com as variáveis que saem muito antes de modo adiantado, i.e. incluímos a variável adiantada (em  $t + 1$ ) entre os  $\mathbf{X}_t$  no modelo VAR.
    - No entanto, essa estratégia é menos útil quando o calendário de divulgações é mais irregular e com menos intervalos entre divulgações.
    - Além disso, defasar algumas séries pode complicar a interpretação dos resultados das estimações.

## PREVISÃO ONLINE E NOWCASTING

- A alternativa para os cenários com divulgação irregular, que mantém a interpretabilidade dos coeficientes, consiste em realizar um procedimento conhecido como *nowcasting*.
- Formalmente, suponha que podemos dividir o VAR em dois conjuntos de variáveis  $\mathbf{X}_t = [\mathbf{X}_t^e, \mathbf{X}_t^I]$ .
  - Para as variáveis em  $\mathbf{X}_t^e$ , observamos os dados até  $T + 1$ .
  - Para as variáveis em  $\mathbf{X}_t^I$ , observamos os dados até  $T$ .
- Sejam  $\hat{\mathbf{a}}_0$ ,  $\{\hat{\mathbf{A}}_k\}_{k=1}^p$  e  $\hat{\Sigma}_0$  estimadores dos parâmetros do VAR com base em dados até  $T$ .
  - Para esse conjunto de dados, não faltam informações para resolver o problema de otimização que produz o estimador.
- Ideia é incorporar na projeção de  $\mathbf{X}_t^I$  nossa melhor projeção para  $\epsilon_{T+1}^I$ .
  - Quando não temos dados de  $T + 1$ , sabemos que nossa melhor projeção para esse termo é  $\mathbf{0}$ , visto que se trata de um ruído branco.
  - No entanto, conhecimento de  $\mathbf{X}_{T+1}^e$  é possivelmente informativo sobre ruído branco, visto que há potencial correlação contemporânea nestes.

# NOWCASTING

- Possível mostrar que melhor projeção (linear) para  $\epsilon_{T+1}^l$  com base no conhecimento do passado e  $\mathbf{X}_{T+1}^e$  é:

$$\mathbf{s}_{T+1}^l = \Sigma_{l,e} \Sigma_{e,e}^{-1} \epsilon_{T+1}^e$$

onde  $\Sigma_{e,e} = \mathbb{V}[\epsilon_t^e]$  e  $\Sigma_{l,e} = \text{cov}[\epsilon_t^l, \epsilon_t^e]$ .

- Ideia é estimar  $\mathbf{s}_{T+1}^l$  como:

$$\hat{\mathbf{s}}_{T+1}^l = \hat{\Sigma}_{0,l,e} \hat{\Sigma}_{0,e,e}^{-1} (\mathbf{X}_{T+1}^e - \hat{\mathbf{X}}_{T+1|T}^e),$$

onde  $\hat{\mathbf{X}}_{T+1|T}^e$  é a projeção usual do VAR com dados até  $T$ , para  $T+1$ .

- Projetamos  $\mathbf{X}_{T+1}^l$  como:

$$\hat{\mathbf{X}}_{T+1}^l = \hat{\mathbf{X}}_{T+1|T}^l + \hat{\mathbf{s}}_{T+1}^l$$

- $\hat{\mathbf{s}}_{T+1}^l$  é o **ganho informacional** da divulgação adiantada de  $e$ .
- Projeções para o horizonte longo são feitas de forma recursiva, usando  $\hat{\mathbf{X}}_{T+1}^l$  e  $\mathbf{X}_{T+1}^e$  para  $T+1$ .

# Conceitos de interrelação para processos multivariados

# DISTRIBUIÇÕES CONJUNTAS DE PROCESSOS VETORIAIS

- Seja  $\{\mathbf{Z}_t\}_{t \in \mathbb{Z}}$  um processo vetorial de interesse.
- A densidade conjunta numa janela  $\{\mathbf{Z}_t\}_{t=1}^T$ , condicional a um valor inicial  $\mathbf{Z}_0$ , fatora-se como:

$$f[(\mathbf{Z}_t)_{t=1}^T | \mathbf{Z}_0] = \prod_{t=1}^T f[\mathbf{Z}_t | \mathcal{Z}_{t-1}],$$

onde  $\mathcal{Z}_{t-1} = (\mathbf{Z}_0, \mathbf{Z}_1, \dots, \mathbf{Z}_{t-1})$ .

## CAUSALIDADE DE GRANGER

- Particione  $\mathbf{Z}_t$  em dois conjuntos de variáveis,  $\mathbf{Z}_t^1$  e  $\mathbf{Z}_t^2$ , com  $d_1 + d_2 = d$ .
- Dizemos que  $\mathbf{Z}_t^2$  não Granger causa  $\mathbf{Z}_t^1$  se:

$$f(\mathbf{Z}_t^1 | \mathcal{Z}_{t-1}) = f(\mathbf{Z}_t^1 | \mathcal{Z}_{t-1}^1),$$

onde  $\mathcal{Z}_{t-1}^1 = (\mathbf{Z}_0^1, \mathbf{Z}_1^1, \dots, \mathbf{Z}_{t-1}^1)$ .

- $\mathbf{Z}_t^2$  não Granger causa  $\mathbf{Z}_t^1$  se defasagens de  $\mathbf{Z}_t^2$  não são informativas sobre  $\mathbf{Z}_t^1$ .
  - Conceito preditivo, e não causal (no sentido econométrico do termo), embora o termo causalidade esteja no nome.
- Em um modelo VAR(p) para  $\mathbf{Z}_t$ , onde  $\mathbf{A}_l = \begin{bmatrix} \mathbf{A}_{l,1,1} & \mathbf{A}_{l,1,2} \\ \mathbf{A}_{l,2,1} & \mathbf{A}_{l,2,2} \end{bmatrix}$ , nula de que  $\mathbf{Z}_t^2$  não Granger causa  $\mathbf{Z}_t^1$  é equivalente a:

$$H_0 : \mathbf{A}_{l,1,2} = \mathbf{0}_{d_1 \times d_2}, \quad l = 1, \dots, p.$$



# CAUSALIDADE DE GRANGER, CAUSALIDADE CONTEMPORÂNEA E EXOGENEIDADE FRACA

- Conceito de causalidade de Granger nos diz que conhecimento do passado de  $\mathbf{Z}_t^2$  não é informativo sobre  $\mathbf{Z}_t^1$  contemporâneo.
- Note que não falamos nada sobre conhecimento **contemporâneo** de  $\mathbf{Z}_t^2$  ser informativo sobre  $\mathbf{Z}_t^1$  contemporâneo.
  - De fato, num VAR,  $\mathbf{Z}_t^2$  é no geral contemporaneamente informativo sobre  $\mathbf{Z}_t^1$  por conta das correlações em  $\mathbb{V}(\epsilon_t)$  diferentes de zero.
  - No VAR, é possível testar essas relações contemporâneas olhando-se para as entradas de  $\mathbb{V}(\epsilon_t)$  (“**causalidade**” **contemporânea**; também um conceito preditivo).
    - Nula de não causalidade contemporânea é que coeficiente do melhor preditor linear de  $\epsilon_t^2$  em  $\epsilon_t^1$  é zero, i.e.  $\text{cov}(\epsilon_t^1, \epsilon_t^2) \mathbb{V}[\epsilon_t^2]^{-1} = \mathbf{0}_{d_1 \times d_2}$ .
- Um conceito relacionado, embora diferente da causalidade de Granger, diz respeito à modelagem da distribuição de  $\mathbf{Z}_t^2$  ser importante, do ponto de vista estatístico, na estimação do modelo para  $\mathbf{Z}_t^1$ .
- A esse conceito damos o nome de **exogeneidade fraca**.

# MODELO CONDICIONAL E EXOGENEIDADE FRACA

- Formalmente, um modelo é uma parametrização da distribuição condicional  $f[\mathbf{Z}_t|\mathcal{Z}_{t-1}] = f[\mathbf{Z}_t|\mathcal{Z}_{t-1}; \theta_0]$ , onde  $\theta_0 \in \Theta$  é um parâmetro desconhecido, que toma algum valor em  $\Theta$ .
- Note que sempre podemos escrever, usando a regra de Bayes:

$$f[(\mathbf{Z}_t)_{t=1}^T|Z_0; \theta_0] = \prod_{t=1}^T f[\mathbf{Z}_t|\mathcal{Z}_{t-1}; \theta_0] = \prod_{t=1}^T f[\mathbf{Z}_t^1|\mathbf{Z}_t^2, \mathcal{Z}_{t-1}; \theta_0]f[\mathbf{Z}_t^2|\mathcal{Z}_{t-1}; \theta_0],$$

- Nesse contexto, um subconjunto  $\psi$  dos parâmetros  $\theta_0$  é dito **fracamente exógeno com respeito a  $\mathbf{Z}_t^2$**  se podemos reescrever:

$$f[\mathbf{Z}_t^1|\mathbf{Z}_t^2, \mathcal{Z}_{t-1}; \theta_0]f[\mathbf{Z}_t^2|\mathcal{Z}_{t-1}; \theta_0] = f[\mathbf{Z}_t^1|\mathbf{Z}_t^2, \mathcal{Z}_{t-1}; \lambda_1]f[\mathbf{Z}_t^2|\mathcal{Z}_{t-1}; \lambda_2]$$

onde  $\psi$  é função somente de  $\lambda_1$ , e  $\lambda_1$  e  $\lambda_2$  podem variar **livremente**.

- No caso, não há perda de informação relevante em estimar  $\psi$  somente considerando o modelo  $\mathbf{Z}_t^1|\mathbf{Z}_t^2, \mathcal{Z}_{t-1}$ , tratando  $\mathbf{Z}_t^2$  como fixo.

## EXOGENEIDADE FORTE

- O conceito de exogeneidade fraca nos diz que, para estimar  $\psi$ , não há perda de informação em considerar o modelo para  $\mathbf{Z}_t^1 | \mathbf{Z}_t^2, \mathcal{Z}_{t-1}$ .
- Se formos realizar previsões para  $\mathbf{Z}_{T+h}^1$  com base nesse modelo, no entanto, vamos precisar de projeções para  $\mathbf{Z}_{T+h}^2$ .
- Podemos fazer isso imputando  $\mathbf{Z}_{T+h}^2$  com base nas projeções de um modelo para  $\mathbf{Z}_{T+h}^2$  com base somente no seu passado?
  - Isso só faz sentido em termos estatístico-preditivos se  $\mathbf{Z}_{T+h}^1$  **não Granger causa**  $\mathbf{Z}_{T+h}^2$ .
  - Nesse caso, podemos modelar  $\mathbf{Z}_{T+h}^2$  externamente e somente incluir suas projeções futuras no modelo para  $\mathbf{Z}_t^1 | \mathbf{Z}_t^2, \mathcal{Z}_{t-1}$ .
- Exogeneidade fraca de  $\mathbf{Z}_t^2$  com respeito a  $\psi$  + não causalidade de Granger  $\mathbf{Z}_t^1$  sobre  $\mathbf{Z}_t^2$ :  $\mathbf{Z}_t^2$  é **fortemente exógeno** com respeito a  $\psi$ .

# ANÁLISE CONTRAFACTUAL E SUPER EXOGENEIDADE

- Retorne à fatoração da densidade conjunta:

$$f[\mathbf{Z}_t | \mathcal{Z}_{t-1}; \theta_0] = f[\mathbf{Z}_t^1 | \mathbf{Z}_t^2, \mathcal{Z}_{t-1}; \lambda_1] f[\mathbf{Z}_t^2 | \mathcal{Z}_{t-1}; \lambda_2]$$

- Essa fatoração, nos sugere um método para avaliar intervenções alternativas em  $\mathbf{Z}_t^2$ , que aqui são medidas por mudanças na distribuição  $\mathbf{Z}_t^2 | \mathcal{Z}_{t-1}$ .
  - Se  $\mathbf{Z}_t^2$  é a taxa de juros e  $\mathbf{Z}_t^1$  compila inflação e taxa de desemprego, qual seria o comportamento da taxa de juros sobre uma regra de decisão alternativa?
- Formalmente, a avaliação de políticas alternativas (contrafactuais) com base na estimação de  $\hat{\lambda}_1$  só será válida sobre um requerimento adicional à exogeneidade fraca, denominado **invariância**.
  - $\mathbf{Z}_t^1 | \mathbf{Z}_t^2, \mathcal{Z}_{t-1}$  é invariante se modelo e seu parâmetro para  $f[\mathbf{Z}_t^1 | \mathbf{Z}_t^2, \mathcal{Z}_{t-1}; \lambda_1]$  não mudam sob distribuições alternativas para  $\mathbf{Z}_t^2 | \mathcal{Z}_{t-1}$ .
- Exogeneidade fraca + invariância: **superexogeneidade** com respeito a um parâmetro.

# INVARIÂNCIA E CRÍTICA DE LUCAS

- Num VAR(p) de inflação, desemprego e taxa de juros, a hipótese de invariância para avaliação do efeito contrafactual de regra de juros alternativos parece razoável?
- A **crítica clássica de Lucas** sugere que, na medida em que as decisões de produção e preço de uma economia são tomadas por agentes racionais que levam em conta expectativas acerca do regime em questão, a resposta é **não**.
- Nesse caso, os parâmetros do VAR(p) em questão são funções complicadas dos parâmetros fundamentais da Economia (preferências, parâmetros da função de produção e política econômica), de modo que existe uma relação complicada entre os parâmetros de equações diferentes de um VAR(p).
  - Não podemos simplesmente alterar uma das equações do modelo, mantendo as demais fixas nos valores estimados.
  - Além disso, note que as equações do modelo, a princípio, também não são necessariamente funções política passíveis de modificação, e sim objetos de equilíbrio.

## ALTERNATIVAS À CRÍTICA DE LUCAS

- A crítica de Lucas ensejou duas tradições na macroeconometria.
- A tradição de DSGE busca partir de modelos econômicos estocásticos microfundamentados e completamente especificados, e derivar um VAR(p) a partir das primitivas do modelo econômico e de hipóteses de equilíbrio do sistema.
- Formalmente, o VAR(p) resultante se escreve nesses casos como

$$\mathbf{Z}_t = \mathbf{a}_0(\xi) + \mathbf{A}_1(\xi)\mathbf{Z}_{t-1} + \mathbf{A}_2(\xi)\mathbf{Z}_{t-2} + \dots + \mathbf{A}_p(\xi)\mathbf{Z}_{t-p} + \epsilon_t(\xi),$$

onde  $\xi$  são os parâmetros fundamentais (preferências, tecnologia, política fiscal e monetária etc.), e tanto os choques como  $\mathbf{A}_i$  são funções complicadas desses parâmetros que emergem do equilíbrio do sistema.

- Ideia é estimar  $\xi$  indiretamente a partir do VAR(p), e realizar os contrafactuais variando-se  $\xi$ .
  - Dificuldades de identificação, estimação e inferência.
  - Além disso, método depende muito da correta especificação do modelo.

## VAR (SEMI)ESTRUTURAL

- Uma segunda tradição busca postular modelos que, partindo da teoria econômica, explicitem as relações causais entre as variáveis, embora sejam agnósticos sobre os microfundamentos específicos dos problemas.
  - Diversos modelos econômicos postulam relações contemporâneas e extemporâneas entre desemprego, juros e inflação.
- Definido o modelo, analisamos condições que garantam que sejamos capazes de avaliar o efeito de choques (surpresas) nas variáveis de política econômica sobre as demais variáveis, **no regime em questão**.
  - Análise de natureza causal, embora não contrafactual (visto que mantemos o regime atual).
  - Para análise contrafactual, precisamos de mais hipóteses, visto que não postulamos todos os microfundamentos como na abordagem DSGE.
- Abordagem de VAR (semi)estrutural, que veremos mais à frente no curso.